Comparaison des Réseaux de Neurones vs Methodes classiques

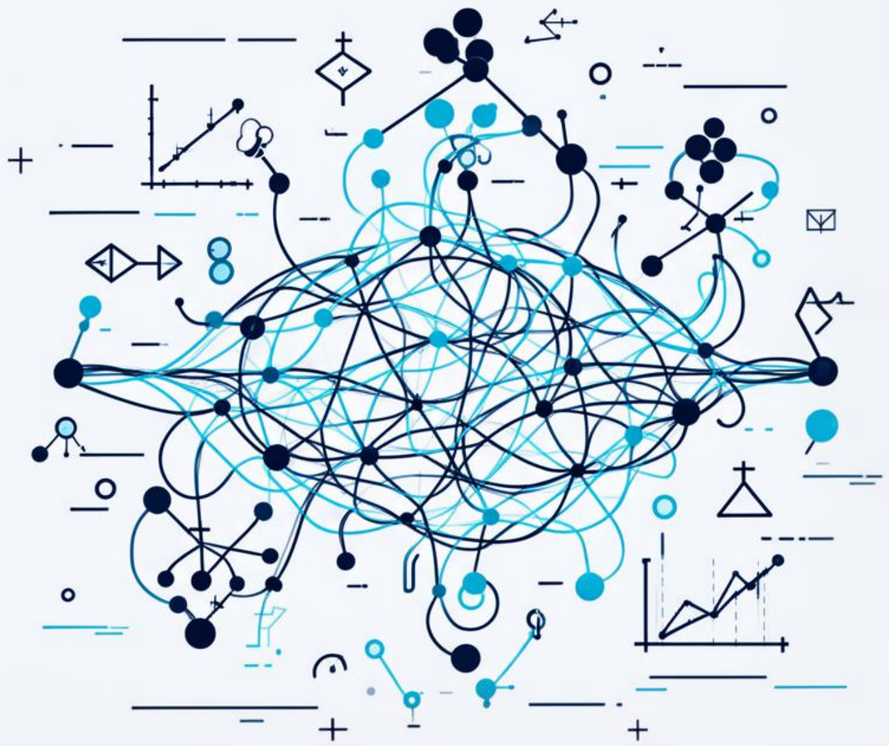

Réalisé par :
Bensaadoun Aymane
Genin Amine

Sommaire

01 Introduction

02 Préparation du Dataset

03 Modèles

04 Analyse des Résultats Graphiques

05 Tableau Comparatif Global

06 Conclusion Générale

Introduction

Dans ce projet, nous avons travaillé sur le **dataset Titanic**, dont l'objectif est de prédire si un passager a survécu ou non au naufrage.
La variable cible est :

- **Survived** : 1 si le passager a survécu, 0 sinon.

Pour effectuer cette prédiction, nous avons utilisé plusieurs variables explicatives :

- **Pclass** : classe du passager
- **Sex** : sexe
- **Age** : âge
- **SibSp** : nombre de frères ou époux à bord
- **Parch** : nombre de parents ou enfants à bord
- **Fare** : prix du billet
- **Embarked** : port d'embarquement

Introduction (Suite)

L’objectif du projet

L’objectif principal de ce projet est de comparer les performances de différentes méthodes de classification — **KNN**, **SVM**, **Régression Logistique** et **Réseau de Neurones (MLP)** — appliquées au **dataset Titanic**.
Cette comparaison vise à analyser :

- La **performance prédictive** (Accuracy, Precision, Recall, F1-score)
- La **complexité** (temps d’entraînement et de prédiction)
- La **robustesse** face au bruit

Préparation du Dataset

Étape 1 – Traitement des valeurs manquantes

- Certaines variables du **dataset** contenaient des valeurs manquantes. Afin d'éviter les erreurs lors de l'entraînement des modèles, nous avons remplacé les valeurs numériques par la médiane et les variables catégorielles par la valeur la plus fréquente.Cela permet de conserver les données tout en assurant la stabilité du modèle.

```python
if "Age" in df.columns:
    df["Age"] = df["Age"].fillna(df["Age"].median())
```

```python
if "Embarked" in df.columns:
    df["Embarked"] = df["Embarked"].fillna(df["Embarked"].mode()[0])
```

Étape 2– Encodage des variables catégorielles

- Les variables textuelles ont été converties en valeurs numériques à l'aide du One-Hot Encoding pour permettre leur utilisation par les modèles.

```python
cat_cols = [c for c in ["Sex", "Embarked"] if c in df.columns]
df = pd.get_dummies(df, columns=cat_cols, drop_first=True)
```

Préparation du Dataset

Étape 3 – Séparation Features / Target

- Nous avons séparé la variable cible des variables explicatives. La variable cible est **Survived**, qui représente la valeur à prédire. Les autres colonnes constituent les **features**, utilisées comme variables d'entrée du modèle

```python
target = "Survived"          # ce qu'on veut prédire
X = df.drop(columns=[target])  # toutes les colonnes sauf la cible
y = df[target]                 # la cible 0/1
```

Étape 4– Division Train / Test

- Le dataset a été divisé en deux ensembles :

Un ensemble d'entraînement pour apprendre le modèle.
Un ensemble de test pour évaluer ses performances.

```python
X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    test_size=TEST_SIZE,
    random_state=RANDOM_STATE,
    stratify=y
)
```

Modèles utilisés

KNN

L'algorithme **KNN** (K-Nearest Neighbors) classifie en fonction des voisins les plus proches, offrant une simplicité d'utilisation.

SVM

Le **SVM** (Support Vector Machine) cherche à créer une frontière optimale pour séparer les classes, maximisant la marge entre elles.

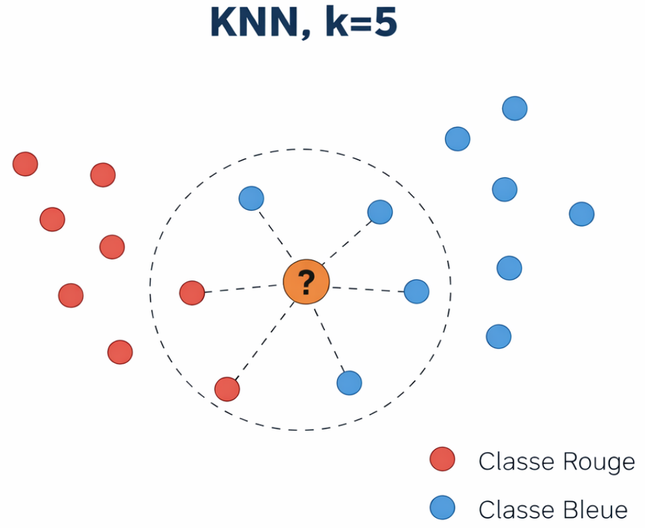

Principe : classification basée sur la distance.

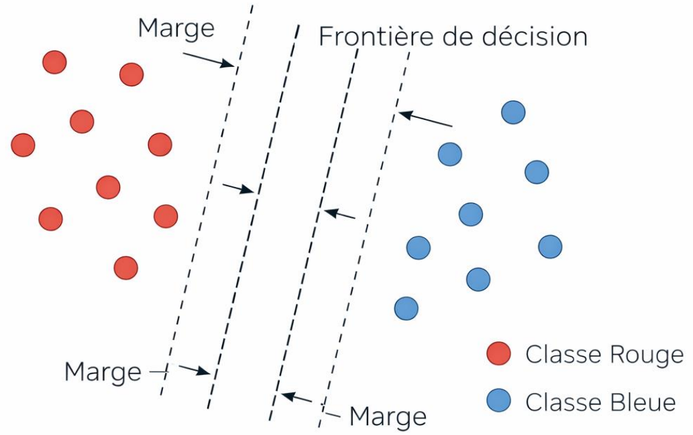

Principe : séparation optimale des classes par une marge maximale.

Modèles utilisés

RÉGRESSION LOGISTIQUE

La **régression logistique** est un modèle de classification qui transforme une combinaison linéaire des variables en une probabilité comprise entre 0 et 1 .

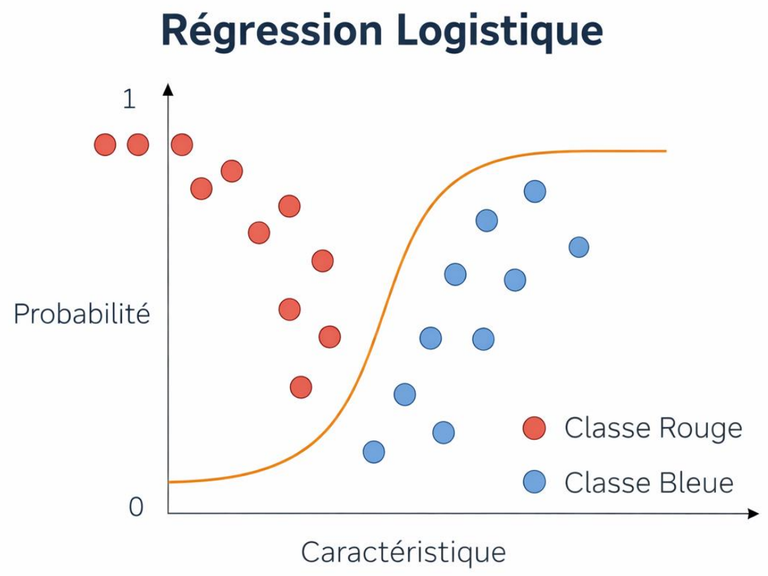

Principe : estimation d'une probabilité via fonction sigmoïdè.

Réseau de Neurones (MLP – Multilayer Perceptron)

le **réseau de neurones est** un modèle composé de plusieurs couches de neurones artificiels qui permet d'apprendre des relations complexes entre les variables.

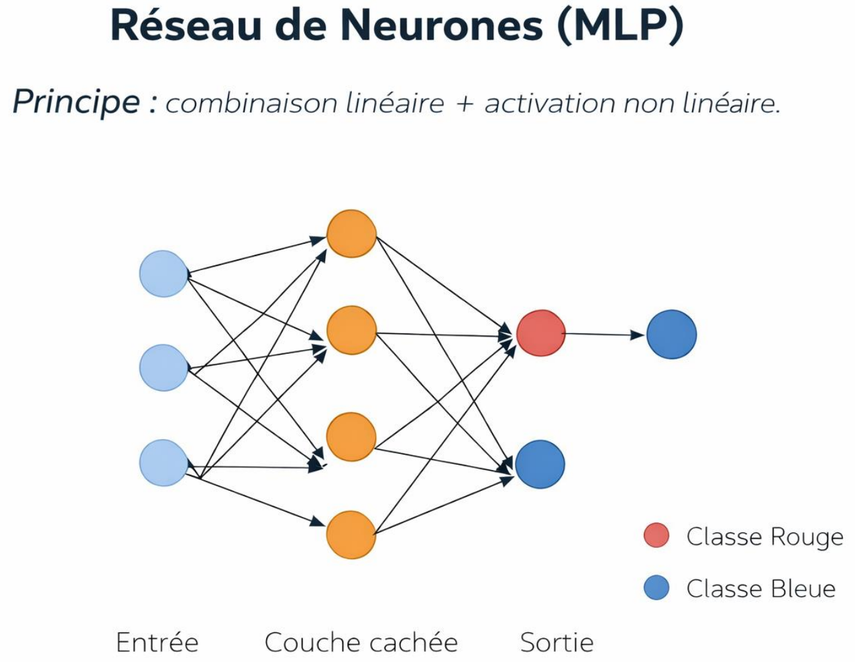

Analyse des Résultats Graphiques

Comparaison des métriques principales

- Ce graphique illustre la comparaison des performances des quatre modèles à travers les principales métriques d'évaluation : Accuracy, Precision, Recall et F1-score.
  Les résultats sont globalement similaires, avec une légère avance du SVM en termes de précision.
  Les autres modèles présentent des performances stables et comparables.

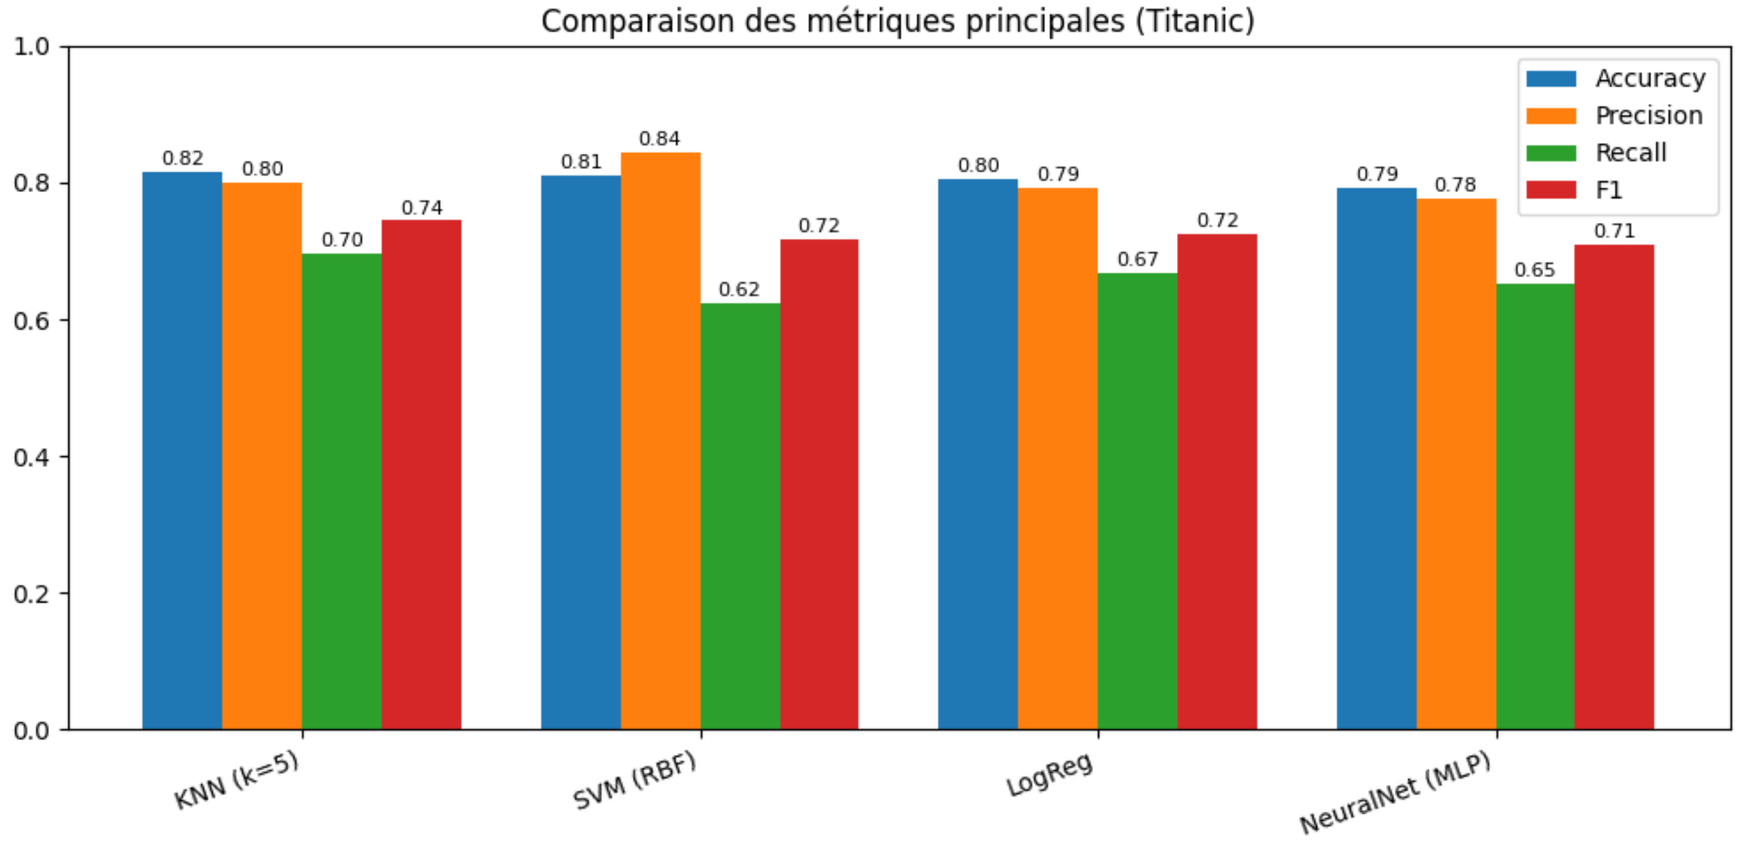

Analyse des Résultats Graphiques

Comparaison du temps d'entraînement et de prédiction

- Ce graphique compare le temps d'entraînement et le temps de prédiction des différents modèles.
  On observe que **le réseau de neurones (MLP)** nécessite un temps d'entraînement plus élevé.
  Les modèles classiques comme **KNN**, **SVM** et **Régression Logistique** sont beaucoup plus rapides.

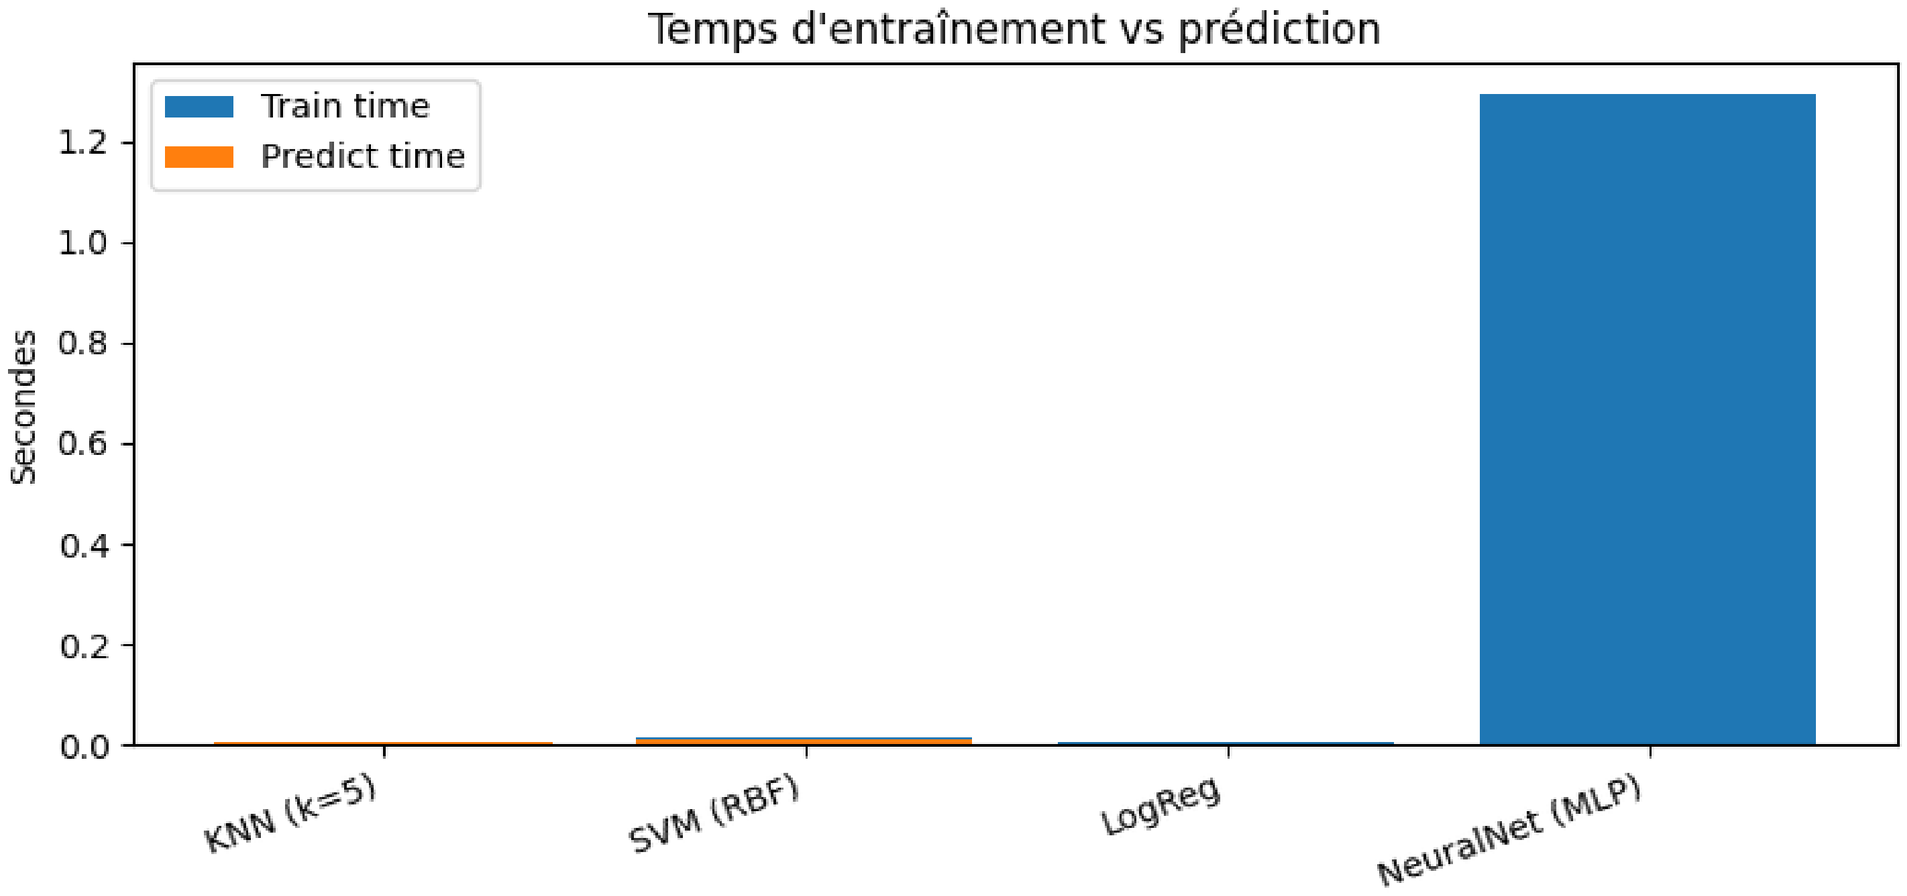

Analyse des Résultats Graphiques

Analyse de la robustesse face au bruit

- Ce graphique montre l'effet du bruit sur les performances . On remarque que les modèles restent presque stables même quand le bruit augmente . Cela signifie qu'ils sont globalement **robustes**.

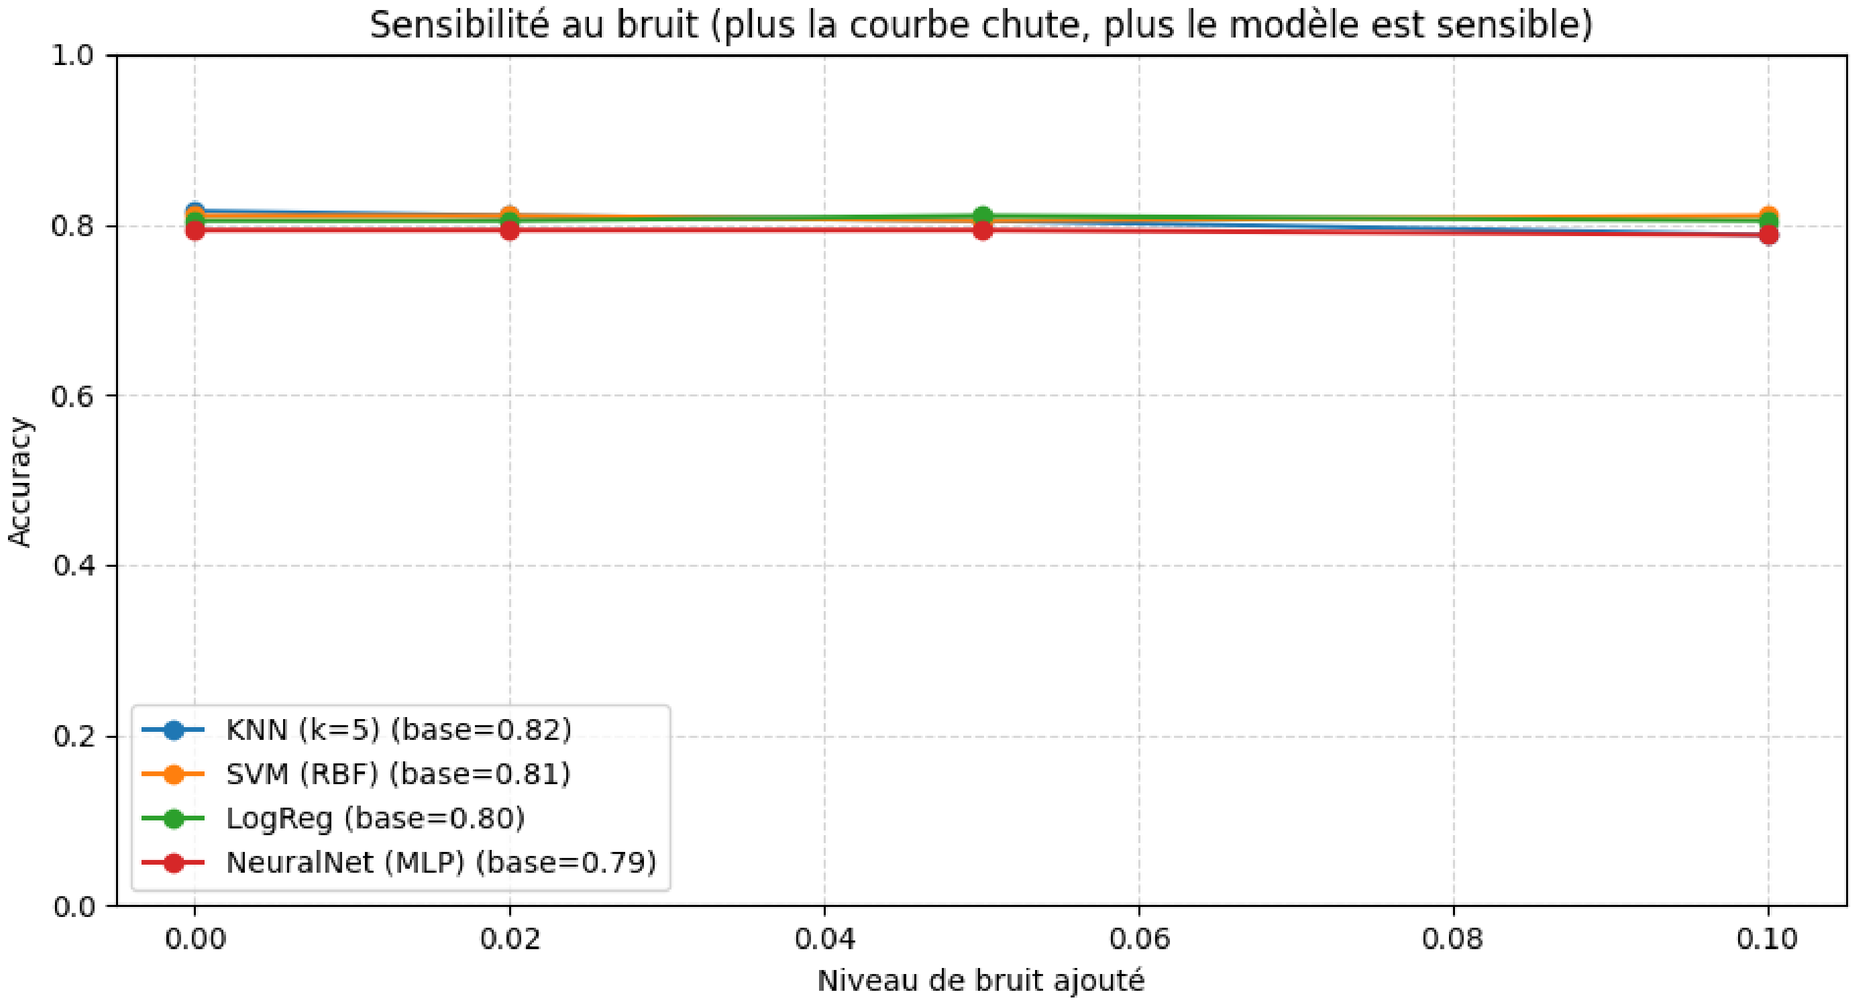

Tableau Comparatif

Modèle	Performance globale	Temps d'entraînement	Robustesse au bruit	Complexité
KNN (k=5)	Bonne	Rapide	Bonne	Faible
SVM	Très bonne	Moyen	Très bonne	Moyenne
Régression Logistique	Bonne	Très rapide	Bonne	Faible
Réseau de Neurones (MLP)	Bonne	Élevé	Bonne	Élevée

- Ce tableau résume les points forts de chaque modèle.
  Le SVM offre la meilleure performance globale.
  La régression logistique est la plus rapide.
  Le réseau de neurones est plus complexe et demande plus de temps d'entraînement.
  Tous les modèles restent globalement robustes face au bruit.

Implément-ation du Code

Conclusion Générale

- En conclusion, ce projet nous a permis de comparer plusieurs modèles de classification afin de prédire la survie des passagers du Titanic.

- Les résultats montrent que les modèles sont capables de distinguer efficacement les passagers survivants de ceux décédés, en se basant sur des variables comme l'âge, le sexe et la classe.

- Le **SVM** présente légèrement les meilleures performances globales, tandis que la régression logistique est la plus rapide. Le **réseau de neurones est plus complexe** mais reste performant.

- Enfin, tous les modèles démontrent une bonne **robustesse face au bruit**, ce qui confirme la fiabilité des prédictions obtenues.

Merci pour votre attention